

基于 CEEMD-WOA-LSTM 的光伏发电功率预测

李恺丽, 王剑斌, 沈怡俊, 陈 博

(浙江工业大学 信息工程学院, 浙江 杭州 310032)

摘要: 针对实际电力系统中光伏发电的波动性和不确定性, 建立了基于 CEEMD-WOA-LSTM 的光伏发电功率预测模型。首先, 采用皮尔逊相关系数法确定辐照度、湿度、温度和风速为光伏功率的关键影响因素, 基于高斯混合模型聚类将数据集分为晴天、多云、雨天 3 种天气类型, 以降低训练集与测试集之间的差异并提高预测模型的泛化能力, 从而完成数据预处理。其次, 采用互补集合经验模态分解对预处理后的数据进行分解并重构, 降低其强随机性和复杂性, 通过长短期记忆神经网络对分解所得的各本征模态函数分量进行功率预测, 并利用鲸鱼优化算法优化网络参数以提升预测精度, 从而叠加各分量的预测结果以确定最终预测值。最后, 通过实验验证所提方法的有效性。结果表明: 与现有方法相比, 在不同天气条件下 CEEMD-WOA-LSTM 的预测精度均有所提高, 且在复杂天气条件时展现出更好的稳定性和鲁棒性。

关键词: 光伏功率预测; CEEMD; LSTM 神经网络; 鲸鱼优化算法

中图分类号: TM615 **文献标识码:** A **DOI:** 10.16146/j.cnki.rndlgc.2025.02.016

[引用本文格式] 李恺丽, 王剑斌, 沈怡俊, 等. 基于 CEEMD-WOA-LSTM 的光伏发电功率预测[J]. 热能动力工程, 2025, 40(2): 136-147. LI Kaili, WANG Jianbin, SHEN Yijun, et al. Prediction of photovoltaic power generation based on CEEMD-WOA-LSTM[J]. Journal of Engineering for Thermal Energy and Power, 2025, 40(2): 136-147.

Prediction of Photovoltaic Power Generation based on CEEMD-WOA-LSTM

LI Kaili, WANG Jianbin, SHEN Yijun, CHEN Bo

(College of Information Engineering, Zhejiang University of Technology, Hangzhou, China, Post Code: 310032)

Abstract: A photovoltaic (PV) power prediction model based on CEEMD-WOA-LSTM was established to address the fluctuation and uncertainty issues of PV power generation in practical power systems. Firstly, the Pearson correlation coefficient method was used to determine irradiance, humidity, temperature, and wind speed as the key influencing factors of PV power. Based on the Gaussian mixture model clustering, the dataset was divided into three weather types including sunny, cloudy, and rainy, to reduce the difference between the training and testing sets and improve the generalization ability of the prediction model, thus completing data preprocessing. Secondly, complementary ensemble empirical mode decomposition (CEEMD) was adopted to decompose and reconstruct the preprocessed data to reduce its strong randomness and complexity. Long short-term memory (LSTM) neural network was used to predict the power of each decomposed intrinsic mode function (IMF), and the whale optimization algorithm (WOA) was used to optimize network parameters to enhance prediction accuracy. Thus, the predicted results of each component were superimposed to determine the final predicted value. Finally, the effectiveness of the proposed method was validated through experiments. The results show that compared with existing methods, CEEMD-WOA-LSTM shows improved prediction accuracy under different weather conditions and demonstrates better stability and robustness under complex weather conditions.

Key words: photovoltaic power prediction, CEEMD, LSTM neural network, whale optimization algorithm (WOA)

引言

光伏发电作为一种能够直接将太阳能转换为电能的技术,以其安全高效、经济环保的优势越来越受到重视。然而,光伏发电功率易受季节、天气等因素影响,使功率呈现出明显的随机性和波动性,将光伏发电装置接入电力系统会给她带来冲击与挑战^[1-2]。加强对光伏发电功率的准确预测不仅可以帮助电网运营商更好地调度发电资源、优化电力系统运行,也能减少电力系统对调峰备用电源的依赖,从而降低运营成本。因此,光伏发电功率预测是现代电力系统平稳运行的重要支撑。

目前,对光伏发电功率的预测研究主要集中在提高预测精度、降低计算复杂度和解决数据不确定性等方面。根据预测模型的分类,主要可以分为统计学方法和人工神经网络方法^[2-3]。统计学方法包括多元线回归^[4-5]和时空序列模型^[6]等,这些方法依赖大量光伏数据,数据处理较为复杂,因此应用难度大、实际应用少。相比之下,人工神经网络方法不需要预先设定严格的数学模型,具备学习历史数据中内在特征关系并不断加强预测的能力^[7]。循环神经网络^[8]、极限学习机^[9]和长短期记忆网络(Long Short-Term Memory, LSTM)^[10]等多种神经网络模型已经应用于光伏功率预测领域。文献[11]对比了 LSTM、门控循环单元和栈式自编码器在电力负荷预测中的性能,并验证 LSTM 在处理高度非线性数据时具有较强的适用性和学习能力,能够精确高效地比较和更新记忆信息和当前信息。文献[12]对比了 LSTM、卷积神经网络以及其组合模型在光伏发电功率预测中的性能,结果表明组合模型的预测精度优于单一模型。基于上述研究, LSTM 在面对光伏数据时预测能力表现优秀,本文拟采用 LSTM 作为骨干网络,结合优化算法实现光伏发电功率的预测。

人工神经网络方法在光伏功率预测领域已经证明其有效性,但在参数优化和配置方面仍面临显著挑战。传统的基于梯度的优化方法虽普遍适用于神经网络的训练,但因其容易陷入局部最优而受到限制。近年来,具有全局搜索能力的启发式优化算法

被广泛应用,如遗传算法^[13]、粒子群优化算法^[14]和蚁群优化算法^[15]等。鲸鱼优化算法(Whale Optimization Algorithm, WOA)是一种新型的启发式优化算法,针对神经网络训练中的参数优化问题,通过模拟鲸鱼的捕食和迁徙行为,实现强大的全局搜索能力,该算法能有效找到最优参数^[16-17]。该优化算法不需要复杂的参数设置,并且收敛速度较快。WOA 可以自动搜索神经网络模型中的最优参数组合,包括隐藏层节点数、学习速率和 Dropout 率等关键参数,实现预测模型性能的提升。

尽管 LSTM 在处理非线性长序列时表现良好,但光伏数据的复杂性对 LSTM 预测光伏功率仍然是一个挑战。针对这一问题,利用信号分解技术将复杂信号分解为一系列固有模态函数,可以实现对光伏数据的有效处理。信号分解技术在光伏功率预测领域引起了广泛关注,文献[18]利用经验模态分解(Empirical Mode Decomposition, EMD)对原始光伏数据进行分解处理,并结合相关向量机建立光伏功率预测模型。文献[19]利用集合经验模态分解(Ensemble Empirical Mode Decomposition, EEMD)对不同天气类型下的光伏功率数据进行分解,并结合广义回归神经网络对光伏功率进行预测。上述方法均对分解信号序列进行建模并完成预测,预测精度较为理想,但在处理强波动序列时均存在明显的模态混叠现象,导致分解信号失真,对模型的预测性能产生不利影响。针对可能出现的模态混叠现象,本文拟采用互补集合经验模态分解(Complementary Ensemble Empirical Mode Decomposition, CEEMD)对光伏功率进行分解处理,该方法在原始信号里分别叠加一组正负相抵的白噪声,实现信号分解准确性和信号重构精度的提升^[20]。

综上所述,本文提出一种基于 CEEMD-WOA-LSTM 的光伏发电功率预测方法。首先,在数据预处理阶段,通过对气象特征的相关性分析选择辐照度、湿度、温度和风速作为模型输入,处理原始数据中的异常值并利用高斯混合模型完成样本聚类。其次,在预测阶段利用 CEEMD 将光伏功率分解为多个本征模态分量并进行重构,再对重构后得到的高频分量、低频分量和趋势项分量分别建立 WOA-

LSTM 预测模型,叠加每个分量的预测值得到最终预测结果。最后,利用实例数据验证模型性能,并与 LSTM、WOA-LSTM 和 EMD-WOA-LSTM 进行对比,证明模型的有效性。

1 数据预处理

将数据预处理过程分为 3 个阶段:首先对气象特征进行相关性分析,再对数据异常值进行处理,最后使用高斯混合模型 (Gaussian Mixture Model, GMM) 完成样本聚类。数据预处理可以显著提升原始数据的有效信息占比,降低模型计算压力并提升预测模型性能。

1.1 气象特征相关性分析

为了提升原始数据中的有效信息占比,降低模型计算压力,提升预测模型性能,须筛选与光伏功率相关性较低的气象特征。皮尔逊相关系数 $P_{X,Y}$ 是应用广泛的相似性指标,通过计算 X,Y 两个样本间的协方差和标准差来衡量两者的关联程度,具体表示为:

$$P_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} \tag{1}$$

$$\text{cov}(X,Y) = E(XY) - E(X)E(Y) \tag{2}$$

$$\sigma_X \sigma_Y = \sqrt{E(X^2) - E^2(X)} \sqrt{E(Y^2) - E^2(Y)} \tag{3}$$

式中: $\text{cov}(X,Y)$ — X 和 Y 的协方差; σ_X, σ_Y — X 和 Y 的标准差; $E(\cdot)$ —数学期望; $P_{X,Y}$ 的值域为 $[-1,1]$, $P_{X,Y} > 0$ 表示正相关, $P_{X,Y} < 0$ 表示负相关,其绝对值越大则相关性越强。

将 DC 国能日新第二届光伏功率预测赛公开数据集^[21]作为训练数据集,对其特征进行相关性分析。该数据集的气象特征包括温度、风速、风向、压强、湿度和辐照度,各气象特征与实际功率的皮尔逊相关系数如图 1 所示。由图可知,辐照度与实际功率相关性最高,相关系数为 0.92;其次是湿度和温度,相关系数分别为 -0.42 和 0.23,其中湿度与实际功率呈负相关;风速与实际功率的相关系数为 -0.17,呈中等负相关;而风向和压强与实际功率呈极弱相关。因此,将辐照度、湿度、温度和风速作为模型输入以预测光伏发电功率。




图 1 各气象特征与实际功率的皮尔逊相关系数

Fig. 1 Pearson coefficients of each meteorological characteristic and actual power

1.2 异常值处理

原始数据中的异常值会影响数据的整体特征分布,对预测效果造成负面影响。因此,本文通过箱型图法检验异常值并进行修正。使用的箱型图法如图 2 所示,定义上四分位数为 Q_1 ,中位数为 Q_2 ,下四分位数为 Q_3 ,四分位距 (Inter Quartile Range, IQR) $IQR = Q_3 - Q_1$,则上界为 $Q_1 + 1.5IQR$,下界为 $Q_3 - 1.5IQR$;当该组数据中的任一值在上界以上或在下界以下时,则将其视为异常值。




图 2 箱型图

Fig. 2 Box plot

完成数据异常校验后,利用平均值法对所有异常值进行修正,具体为:

$$X_t = \frac{X_{t-1} + X_{t+1}}{2} \tag{4}$$

式中: X_t —异常值修正后的值; X_{t-1} —异常值的前一位数据; X_{t+1} —异常值的后一位数据。

异常值的校验及修正可以确保模型不会因少数

异常数据而产生偏差,对于模型的长期稳定性和可靠性至关重要。

1.3 GMM 相似日样本聚类

为确保模型预测的准确性,需要大量数据进行训练。但若训练集与测试集存在数据特征差异,则难以实现理想的预测效果。为此,可以采用聚类方法对光伏数据按天气类型进行聚类,从而降低训练集与测试集之间的差异,提高预测模型的泛化能力。

针对数据中特征复杂、类型分布不均等问题,利用 GMM 进行聚类,该方法是基于概率的聚类方法,比传统的硬聚类更能捕捉数据的细微差别,有利于预测模型更好地学习数据特征。GMM 聚类是由若干高斯模型根据不同概率值混合而成^[22],其中每个单独的高斯模型叫做高斯混合模型的一个高斯分布分量。因此,GMM 的概率密度函数 $P_r(x)$ 可以表示成若干高斯分布分量的加权和:

$$P_r(x) = \sum_{k=1}^K \alpha_k p(x | \mu_k, \sigma_k) \quad (5)$$

$$p(x | \mu_k, \sigma_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \cdot \exp\left(-\frac{(x - \mu_k)^2}{2\sigma_k^2}\right) \quad (6)$$

式中: K —高斯分布分量的个数,即聚类的个数; α_k 、 μ_k 、 σ_k —第 k 个高斯分布分量的概率、均值、协方差。

GMM 聚类的训练过程采用迭代的方式,具体步骤如下:

步骤 1:将每个高斯分布分量的参数 α_0 、 μ_0 、 σ_0 进行初始化。

步骤 2:遍历所有样本点,计算每个样本点 z_i 属于第 k 个高斯分布分量的概率 $\gamma_k(z_i)$,表达式为:

$$\gamma_k(z_i) = \frac{\alpha_k N(z_i | \mu_k, \sigma_k)}{\sum_{k=1}^K \alpha_k N(z_i | \mu_k, \sigma_k)} \quad (7)$$

步骤 3:计算每个高斯分布分量的参数并得到更新后的值,表达式为:

$$\mu_k = \frac{\sum_{i=1}^N \gamma_k(z_i) x_i}{\sum_{i=1}^N \gamma_k(z_i)} \quad (8)$$

$$\sigma_k = \frac{\sum_{i=1}^N \gamma_k(z_i) (z_i - \mu_k) (z_i - \mu_k)^T}{\sum_{i=1}^N \gamma_k(z_i)} \quad (9)$$

$$\alpha_k = \frac{1}{N} \sum_{i=1}^N \gamma_k(z_i) \quad (10)$$

步骤 4:采用更新后的参数,重复步骤 2 和步骤 3,直到模型参数收敛为止。

考虑到晴天、多云和雨天 3 种天气类型能够有效覆盖光伏发电中最关键的环境变量,且能代表大多数典型的天气情况,因此把光伏功率数据分为 3 个数据集,故 K 取 3,再根据光伏发电功率的波动频率特点将 3 个数据集分别标记为晴天、多云和雨天。

2 预测模型构建

在构建预测模型阶段,首先利用互补集合经验模态分解方法对光伏功率进行分解重构,从而获取不同频率分量;然后基于这些分量分别建立 LSTM 预测模型;最后,针对模型参数优化的问题,提出利用 WOA 优化 LSTM 神经网络中的参数,以提高预测模型的准确度。

2.1 互补集合经验模态分解

针对光伏功率曲线的间歇现象以及光伏数据强随机和非线性的特点,利用 CEEMD 将光伏功率分解成若干不同时间特征尺度的本征模态分量 (Intrinsic Mode Function, IMF),可以有效利用光伏发电功率的局部特征,提升预测模型的性能。

CEEMD 是 EMD 针对模态混叠问题的改进,通过向原始信号中加入成对的正负噪声信号 $n_i(t)$ 和 $-n_i(t)$ 解决模态混叠问题。由于加入的白噪声信号是正负成对的,因此重构后信号存在的噪声可以保持在一个很小的量级,不会影响模型的预测效果^[23]。CEEMD 分解步骤如下:

步骤 1:在原始信号 $x(t)$ 中加入成对的正负高斯白噪声 $n_i(t)$,表达式为:

$$\begin{cases} x_i(t) = x(t) + qn_i(t) \\ x'_i(t) = x(t) - qn_i(t) \end{cases} \quad (11)$$

式中: q —所加噪声幅值系数; i —添加噪声的次数。

步骤 2:将加入第 m 次噪声后的 $x_m(t)$ 和 $x'_m(t)$ 进行 EMD 分解。

步骤 3:将 $x_m(t)$ 与 $x'_m(t)$ 分解后得到的各 IMF 分量取平均值,如式 (12) 所示,重复步骤 2 直到遍历所有分量。

$$c_{i,j}(t) = \frac{r_{i,j} + r'_{i,j}}{2} \quad (12)$$

式中: $r_{i,j}$ —第 i 次加入正白噪声后 EMD 分解的第 j 个 IMF 分量; $r'_{i,j}$ —第 i 次加入负白噪声后 EMD 分解的第 j 个 IMF 分量; $c_{i,j}(t)$ —第 i 次加入正负白噪声后分解得到的第 j 个 IMF 分量。

步骤 4:将所有含正负白噪声信号分解得到的对应 IMF 求平均值,得到 CEEMD 的分解结果,表达式为:

$$c_i(t) = \frac{\sum_{j=1}^m c_{i,j}(t)}{m} \quad (13)$$

式中: m —添加白噪声的次数; $c_i(t)$ —CEEMD 分解的第 j 个 IMF, $i=1,2,\dots,m$ 。

CEEMD 分解方法不仅解决了传统分解方法中的模态混叠问题,还可以有效提取信号中的关键特征,包括趋势和周期性等,为构建预测模型奠定了基础。

2.2 长短期记忆神经网络

考虑到光伏功率数据特征分布与时间相关,采用 LSTM 神经网络作为功率预测模型的基本网络。LSTM 神经网络是一种特殊的循环神经网络 (Recurrent Neural Network, RNN), 相比于 RNN, LSTM 具有更好的记忆性,在处理非线性长时间序列问题时收敛速度更快、效果更好^[24]。LSTM 神经网络单元结构如图 3 所示,其中 S 为 sigmoid 激活函数, $\tanh$ 为 $\tanh$ 激活函数, $\odot$ 代表矩阵相乘。




图 3 LSTM 单元结构

Fig. 3 Structure of LSTM unit

由图 3 可知,在 t 时刻的输入信息包括输入序列 x_t 、上一时刻的隐藏层输出 h_{t-1} 和细胞状态 c_{t-1} ;

输出信息包括 t 时刻的隐藏层输出 h_t 和细胞状态 c_t 。其中, x_t 与 h_{t-1} 拼接而得的矩阵作为遗忘门、输入门和输出门的输入变量, c_{t-1} 为其长期记忆, h_{t-1} 为其短期记忆,与输入序列 x_t 共同经过输入门、遗忘门及输出门更新网络信息。根据信息流向可得如下公式:

$$f_t = S(W_f [x_t, h_{t-1}]^T) \quad (14)$$

$$i_t = S(W_i [x_t, h_{t-1}]^T) \quad (15)$$

$$o_t = S(W_o [x_t, h_{t-1}]^T) \quad (16)$$

$$C'_t = \tanh(W_c \cdot h_{t-1} + W_f \cdot x_t) \quad (17)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot C'_t \quad (18)$$

$$h_t = o_t \odot \tanh(C_t) \quad (19)$$

式中: f_t —遗忘门输出值; i_t —输入门输出值; o_t —输出门输出值; W_f —遗忘门的权重; W_i —输入门的权重; W_o —输出门的权重; C'_t — t 时刻细胞状态的输入。

LSTM 神经网络在处理时间序列数据方面表现出色,通过有效捕捉光伏数据中的长期依赖关系,从而实现对光伏功率的预测。

2.3 鲸鱼算法优化长短期记忆神经网络

LSTM 神经网络的参数选择对预测结果的准确性和效率有重要影响,不当的参数选择可能导致学习速率不合适、梯度爆炸以及计算复杂度过高等问题。因此,提出利用 WOA 对 LSTM 神经网络进行优化,WOA 算法流程图如图 4 所示。

其中,参数 p 是 0 ~ 1 随机生成的概率,参数 a 、 A 、 $C(t)$ 的公式如下:

$$a = 2 - \frac{2t}{T} \quad (20)$$

$$A = 2ar - a \quad (21)$$

$$C(t) = 2r \quad (22)$$

式中: t —当前已进行的迭代次数; T —允许的最大迭代次数; a —收敛因子随着迭代过程从 2 线性减小到 0; r —在 0 ~ 1 之间的随机向量;参数 A 、 $C(t)$ 为随收敛因子 a 和随机向量 r 变化的向量。

在收缩包围阶段,第 i 个搜索粒子更新后位置由如下公式得出:

$$x_i(t+1) = x_{\text{best}} - A |C x_{\text{best}} - x_i(t)| \quad (23)$$

在螺旋更新阶段,第 i 个搜索粒子更新后位置由如下公式得出:

$$x_i(t+1) = |x_{\text{best}} - x_i(t)| \cdot e^{bl} \cdot \cos(2\pi l) + x_i(t)$$

(24)

式中: b —常量系数; l — $-1 \sim 1$ 的随机数。




图4 WOA 算法流程图
Fig.4 Flow chart of WOA algorithm

在全局搜索阶段,第*i*个搜索粒子更新后位置由如下公式得出:

$$x_i(t+1) = x_{\text{rand}} - A | Cx_{\text{rand}} - x_i(t) |$$

(25)

式中: x_{rand} —从种群中随机选择的搜索粒子。

WOA 通过模拟鲸鱼觅食行为,在搜索过程中结合了探索性和开发性,有助于更广泛地搜索参数空间,可以有效解决 LSTM 神经网络陷入局部最优解的缺陷,提高参数寻优的准确性。本文以平均绝对误差(Mean Absolute Error,MAE)作为 WOA 的损失函数。适应度函数 TrainingLoss 为:

$$\text{TrainingLoss} = \text{MAE}(h, y) = \frac{1}{m} \sum_{i=1}^m |h(i) - y(i)|$$

(26)

式中: $h(i)$ —预测结果的第*i*个预测值; $y(i)$ —训练数据集中第*i*个实际值; m —预测样本数量。若损失值越小,则预测效果越精确。

WOA-LSTM 整体优化流程如图 5 所示。




图5 WOA-LSTM 流程
Fig.5 Flow chart of WOA-LSTM

3 基于 CEEMD-WOA-LSTM 的光伏发电功率预测

基于 CEEMD-WOA-LSTM 的光伏发电功率预测模型流程如图 6 所示。首先对气象特征进行相关性分析,通过数据预处理及 GMM 聚类得到晴天、多云和雨天 3 种相似日样本,再利用 CEEMD 分别对 3 种天气的光伏功率进行模态分解,将分解得到的 IMFs 根据样本熵重构为高频 IMFs、低频 IMFs 和趋势项 IMFs,然后分别对其建立 WOA-LSTM 预测模型,最后叠加各分量的预测结果,得到最终预测值。该模型的优势在于:

- (1) 充分考虑天气因素的影响,使用 GMM 聚类方法获得相似日样本,提高了预测模型的鲁棒性;
- (2) 有效利用光伏发电功率的局部特征,使用 CEEMD 对数据进行模态分解,有效解决模态混叠造成的原始信号失真问题,分解重构得到的高频、低频和趋势项分量有助于减少原始序列的复杂变化对预测性能的不利影响;
- (3) 使用 WOA 对 LSTM 的参数进行寻优,有效地解决 LSTM 网络容易陷入局部最优解的问题,有

助于提升预测模型的精度。




图 6 基于 CEEMD-WOA-LSTM 的光伏发电功率预测流程

Fig. 6 Flow chart of photovoltaic power generation prediction based on CEEMD-WOA-LSTM

4 实验验证

4.1 评价指标

针对光伏功率预测精度采用平均绝对误差 MAE、均方误差 (Mean Square Error, MSE)、均方根误差 (Root Mean Square Error, RMSE) 作为评价指标,具体表达式为:

$$X_{MAE} = \frac{1}{n} \sum_{i=1}^n | \hat{P}_i - P_i | \tag{27}$$

$$X_{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{P}_i - P)^2 \tag{28}$$

$$X_{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{P}_i - P_i)^2} \tag{29}$$

式中: P_i —光伏发电功率的实际值; $\hat{P}_i$ —光伏发电功率的预测值。

4.2 数据集说明及预处理

采用 DC 国能日新第二届光伏功率预测赛的公开数据集^[21],数据覆盖了 2017 ~ 2018 年,时间间隔为 15 min。鉴于各气象特征的单位 and 区间差异较大,为了便于后续分析与建模,该数据集将所有气象特征数据映射到了 $[-1,1]$ 区间内。

针对数据集中存在的样本缺失问题,考虑到气象数据在时间上的连读性,使用临值插补的方法对缺失值进行填充。其中,2017 年数据集填充 1 981 组数据,2018 年数据集填充 1 649 组数据。为了分析填充缺失值对原始数据的影响,对比填充前后各气象特征及功率的数据统计指标:均值、标准差、方差,如表 1 所示。

表 1 填充前后数据统计指标对比
Tab. 1 Comparison of statistical indicators before and after data imputation

特征	均值		标准差		方差	
	填充前	填充后	填充前	填充后	填充前	填充后
辐照度	-0.58	-0.59	0.55	0.55	0.30	0.31
湿度	-0.28	-0.28	0.43	0.43	0.18	0.19
温度	0.02	0.02	0.39	0.38	0.16	0.14
风速	-0.64	-0.64	0.21	0.21	0.04	0.04
实际功率	3.37	3.40	4.90	4.81	23.99	23.14

由表 1 可知,填充前后的指标没有显著差异,说明通过临值插补法对缺失值进行填充,不仅改善了数据的连续性,也保留了原始数据的规律性。

将填充后的数据集进行异常值检测及修正,在提升了数据质量的基础上,利用 GMM 对样本进行相似日聚类,聚类结果如图 7 所示。可以看出,3 类样本子集的分界较为清晰,说明 GMM 聚类效果好。根据光伏发电功率在一天之内的波动频率特点,可以得到 3 种天气的样本数据:晴天光伏发电功率波动较为平稳,雨天光伏发电功率波动较剧烈,多云光伏发电功率波动介于两者之间^[25]。

考虑到气象特征与季节的强相关性,选取 2017 和 2018 年 3 ~ 5 月的数据作为预测样本,由聚类结果可得,预测样本中有 34 天为雨天,38 天为多云,112 天为晴天。在不同天气类型的预测样本中随机选取 30% 天数作为测试样本,其余作为训练样本。




图7 GMM 聚类结果

Fig. 7 GMM clustering result

将3种天气中的训练样本进行 CEEMD 分解可得到一系列 IMF 分量,以晴天为例,图 8 是晴天下的 CEEMD 分解结果。




图8 晴天训练样本 CEEMD 分解结果

Fig. 8 CEEMD decomposition results of training samples in sunny day

通过计算各 IMF 的样本熵值和所有 IMF 的样本熵均值,可将各 IMF 进行重构,得到高频、低频及趋势项分量序列^[26],IMF 重构所得的 3 种分量如图 9 所示。




图9 IMFs 重构后分量图

Fig. 9 Reconstructed component plots of IMFs

4.3 参数优化过程

以晴天 IMFs 重构后的高频分量为例,设置 WOA 最大迭代次数为 50;设置 LSTM 神经网络学习率取值范围为 0 ~ 0.02,隐藏层节点数取值范围为 5 ~ 200,随机丢弃神经元的概率设置为 0.2。WOA 算法寻优的迭代过程如表 2 所示。

表2 WOA 算法寻优的迭代过程

Tab.2 Iterative process of WOA optimization

迭代次数	学习率	隐藏节点数	随机丢弃概率	适应度
1	0.006 35	16	0.200 00	0.086 3
2	0.013 74	24	0.206 54	0.085 4
3	0.007 54	29	0.248 61	0.082 8
4	0.004 86	35	0.284 26	0.078 5
...	...	...	...	...
36	0.001 232	86	0.252 344	0.045 3

4.4 预测模型有效性验证

为了验证本文所用模型的有效性,针对数据集

中晴天、多云、雨天 3 种天气,在保持参数统一的情况下对 LSTM、WOA-LSTM、EMD-WOA-LSTM 和 CEEMD-WOA-LSTM 进行对比。

考虑到样本量较大,为清晰展示各模型的预测效果,将各模型的预测值与实际值分别进行对比。晴天、多云与雨天 3 种天气各模型的预测结果如图 10 ~ 图 12 所示。




图 10 晴天天气各模型预测结果

Fig. 10 Prediction results of various models in sunny days




图 11 多云天气各模型预测结果

Fig. 11 Prediction results of various models in cloudy days

由图 10 ~ 图 12 可知,3 种天气实际值曲线较平稳的部分,各个模型的性能都表现良好,但是在部分极值点处,LSTM 性能较差,而优化后的 WOA-LSTM 不论是平稳处还是在峰值处都能很好地和实际值曲线拟合。EMD-WOA-LSTM 与 CEEMD-WOA-LSTM

的性能相较于 WOA-LSTM 都有一定提升,由于 EMD 分解存在模态混叠现象,整体拟合程度较 CEEMD-WOA-LSTM 略差。由此可知,CEEMD-WOA-LSTM 的预测效果更好,与原始数据的拟合程度最高。

种天气下的最佳预测效果以加粗形式表示。由表 3 可知,对于 LSTM 和 WOA-LSTM,晴天天气的光伏发电预测精度要优于多云和雨天天气,这是由于晴天天气的样本量最多。3 种天气下 WOA-LSTM 的预测精度均优于 LSTM,由此表明,WOA 具有良好的寻优能力,能够有效地提高 LSTM 的预测性能。结合 EMD 信号分解方法后,EMD-WOA-LSTM 在晴天天气的预测精度较 WOA-LSTM 有所降低,这是由于晴天条件下光伏功率的振荡模式频率接近,增加了 EMD 过程中模态混叠的概率,因此影响了预测精度。在多云和雨天复杂天气条件下,EMD-WOA-LSTM 的预测性能比 WOA-LSTM 更好,由此表明,信号模态分解方法能够改善光伏发电功率数据的随机性和波动性,但需避免模态混叠现象造成的不利影响。而对于 EMD-WOA-LSTM 和 CEEMD-WOA-LSTM 两种模型而言,3 种天气下均是 CEEMD-WOA-LSTM 的误差更小,这说明 CEEMD 方法在处理光伏发电功率数据时更具有优势。CEEMD-WOA-LSTM 的优越性在雨天条件下最为明显,表明该模型在处理复杂和不确定的天气条件时具有良好的鲁棒性。




图 12 雨天天气各模型预测结果

Fig. 12 Prediction results of various models in rainy days

表 3 不同天气各模型预测误差对比

Tab. 3 Comparison of predictive errors of various models under different weathers

天气类型	模型	MAE	MSE	RMSE
晴天	LSTM	0.081 4	0.012 0	0.109 3
	WOA-LSTM	0.041 7	0.003 0	0.054 7
	EMD-WOA-LSTM	0.037 3	0.004 8	0.069 5
	CEEMD-WOA-LSTM	0.020 2	0.002 7	0.051 6
多云	LSTM	0.116 1	0.016 4	0.127 9
	WOA-LSTM	0.053 1	0.005 9	0.076 8
	EMD-WOA-LSTM	0.042 3	0.004 5	0.066 9
	CEEMD-WOA-LSTM	0.035 5	0.003 6	0.060 1
雨天	LSTM	0.299 1	0.112 3	0.335 2
	WOA-LSTM	0.061 4	0.008 1	0.090 0
	EMD-WOA-LSTM	0.053 2	0.007 3	0.085 3
	CEEMD-WOA-LSTM	0.048 0	0.006 5	0.080 5

5 结论与展望

(1) 针对原始光伏发电功率数据,利用 CEEMD 对原始数据进行分解并重构,得到高频、低频和趋势

表 3 为 3 种不同天气各模型预测误差对比,每

项的子序列,很大程度上减少了模态混叠现象,有助于提高分解的准确性和重构信号的精度。

(2) LSTM 隐藏层神经元节点、学习率和 Dropout 参数选择不当会影响预测精度,采用 WOA 优化 LSTM,实现参数动态调整,获得 LSTM 参数最优组合,有效提高了其预测性能。

(3) CEEMD-WOA-LSTM 光伏功率预测模型能够对光伏发电功率做出有效预测,在晴天、多云、雨天 3 种天气下的预测精度都优于其他模型,应用前景良好。

本文在光伏功率预测领域取得了一些成就,但仍存在一些值得进一步研究的问题和挑战。未来的研究可以从以下几个方面进行:

影响光伏发电功率的因素有很多,本文只考虑了辐照度、湿度等几个关键的气象因素,随着光伏发电技术的不断发展,新的数据源和气象特征将不断涌现。如何有效地整合和利用这些多样化的数据,提高预测模型的适应性和准确性,是一个值得探索的方向。

只对光伏数据进行了晴天、多云、雨天的天气类型聚类,再分别建立预测模型。然而,存在 24 小时内多种天气类型交替的复杂天气情况,如何有效地对复杂天气情况进行聚类并建模,对于提升光伏功率预测模型的泛化能力具有重要意义。

只利用了历史数据对光伏功率预测进行了研究,然而实际上这些气象因素会随时间变化而变化,如何构建实时动态的预测模型值得进一步研究。

参考文献:

- [1] 雷鸣宇,杨子龙,王一波,等.光/储混合系统中的储能控制技术[J].电工技术学报,2016,31(23):86-92.
LEI Mingyu, YANG Zilong, WANG Yibo, et al. Study on control technology of energy storage station in photovoltaic/storage system [J]. Transactions of China Electrotechnical Society, 2016, 31(23):86-92.
- [2] 田春光,田利,李德鑫,等.基于混合储能系统跟踪光伏发电输出功率的控制策略[J].电工技术学报,2016,31(14):75-83.
TIAN Chunguang, TIAN Li, LI Dexin, et al. Control strategy for tracking the output power of photovoltaic power generation based on hybrid energy storage system[J]. Transactions of China Electrotechnical Society, 2016, 31(14):75-83.
- [3] 何勇.光伏发电系统功率预测方法研究[D].上海:上海交通大学,2017.
- [4] BESSA R J, TRINDADE A, SILVA C S P, et al. Probabilistic solar power forecasting in smart grids using distributed information[J]. International Journal of Electrical Power & Energy Systems, 2015, 72:16-23.
- [5] BOUZERDOUM M, MELLIT A, PAVAN A M. A hybrid model (SARIMA-SVM) for short-term power forecasting of a small-scale grid-connected photovoltaic plant[J]. Solar Energy, 2013, 98(4):226-235.
- [6] 王佳璆.时空序列数据分析和建模[M].北京:科学出版社,2012.
WANG Jiaqiu. Spatio-temporal sequence data analysis and modeling[M]. Beijing: Science Press, 2012.
- [7] 卢静,翟海青,刘纯,等.光伏发电功率预测统计方法研究[J].华东电力,2010,38(4):563-567.
LU Jing, ZHAI Haiqing, LIU Chun, et al. Study on statistical method for predicting photovoltaic generation power[J]. East China Electric Power, 2010, 38(4):563-567.
- [8] 廖尔泰.基于增强循环神经网络的短期光伏发电功率区间预测方法研究[D].广州:广东工业大学,2023.
LIAO Ertai. Research on short-term photovoltaic power generation power interval prediction method based on enhanced recurrent neural network[D]. Guangzhou: Guangdong University of Technology, 2023.
- [9] 何之倬,张颖,郑刚,等.基于极限学习机模型参数优化的光伏功率区间预测技术[J].上海交通大学学报,2023,57(9):1-21.
HE Zhizhuo, ZHANG Ying, ZHENG Gang, et al. Interval prediction technology of photovoltaic power based on parameter optimization of extreme learning machine[J]. Journal of Shanghai Jiao Tong University, 2023, 57(9):1-21.
- [10] 贾鹏云.基于深度学习算法的短期光伏发电功率预测研究[D].北京:华北电力大学,2021.
JIA Pengyun. Research on short term photovoltaic power prediction based on deep learning[D]. Beijing: North China Electric Power University, 2021.
- [11] 张建寰,吉莹,陈立东.深度学习在电力负荷预测中的应用[J].自动化仪表,2019,40(8):8-12.
ZHANG Jianhuan, JI Ying, CHEN Lidong. Application of deep learning in power load forecasting[J]. Process Automation Instrumentation, 2019, 40(8):8-12.
- [12] WANG K J, QI X X, LIU H D. A comparison of day-ahead photovoltaic power forecasting models based on deep learning neural network[J]. Applied Energy, 2019, 251:113315.
- [13] 胡兵,詹仲强,陈洁,等.基于PCA-GA-Elman的短期光伏出力预测研究[J].太阳能学报,2020,41(6):256-263.
HU Bing, ZHAN Zhongqiang, CHEN Jie, et al. Prediction research

- on short-term photovoltaic output based on PCA-GA-Elman[J]. *Acta Energaie Solaris Sinica*,2020,41(6):256-263.
- [14] 廖志鹏. 基于改进粒子群算法的微电网优化运行研究[D]. 南昌:南昌大学,2020.
- LIAO Zhipeng. Research on microgrid optimization based on improved particle swarm optimization algorithm[D]. Nanchang: Nanchang University,2020.
- [15] 张岩,李洋博,柳 珊,等. 基于蚁群优化神经网络模型的风电功率预测[J]. *内蒙古电力技术*,2019,37(4):26-30.
- ZHANG Yan,LI Yangbo,LIU Shan,et al. Prediction of wind power based on ant colony optimization neural network model[J]. *Inner Mongolia Electric Power*,2019,37(4):26-30.
- [16] 陈友鹏,陈璟华. 基于鲸鱼优化参数的最小二乘支持向量机短期负荷预测方法[J]. *广东工业大学学报*,2020,37(3):75-81.
- CHEN Youpeng, CHEN Jinghua. A short-term load forecasting method based on support vector machine with whale optimization parameters[J]. *Journal of Guangdong University of Technology*, 2020,37(3):75-81.
- [17] MIRJALILI S, LEWIS A. The whale optimization algorithm[J]. *Advances in Engineering Software*,2016,95:51-67.
- [18] 桑康伟. 基于 EMD-RVM 的短期光伏发电预测研究[D]. 芜湖:安徽工程大学,2019.
- SANG Kangwei. Short-term photovoltaic power generation prediction based on EMD-RVM[D]. Wuhu:Anhui Polytechnic University,2019.
- [19] 张 飞,张志伟,万乐斐,等. 基于 EEMD-GRNN 方法的光伏电站短期出力预测[J]. *太阳能学报*,2020,41(12):103-109.
- ZHANG Fei,ZHANG Zhiwei,WAN Lefei,et al. Short-term output prediction of photovoltaic power station based on EEMD-GRNN method[J]. *Acta Energaie Solaris Sinica*,2020,41(12):103-109.
- [20] 曾 亮,狄飞超,兰 欣,等. 基于 CEEMD-CNN-BiGRU-RF 模型的短期风电功率预测[J]. *可再生能源*,2022,40(2):190-195.
- ZENG Liang,DI Feichao,LAN Xin,et al. Short-term wind power prediction based on CEEMD-CNN-BiGRU-RF model[J]. *Renewable Energy Resources*,2022,40(2):190-195.
- [21] DC 竞赛-大数据竞赛平台[EB/OL]. (2018-11-27)[2023-11-08]. <https://challenge.datacastle.cn/v3/cmptDetail.html?id=263>.
- DC competition-Big data competition platform [EB/OL]. (2018-11-27)[2023-11-08]. <https://challenge.datacastle.cn/v3/cmptDetail.html?id=263>.
- [22] 张美霞,李 丽,杨 秀,等. 基于高斯混合模型聚类和多维尺度分析的负荷分类方法[J]. *电网技术*,2020,44(11):4283-4296.
- ZHANG Meixia,LI Li,YANG Xiu,et al. A load classification method based on gaussian mixture model clustering and multi-dimensional scaling analysis[J]. *Power System Technology*,2020,44(11):4283-4296.
- [23] 李秉晨,于惠钧,刘靖宇. 基于 Kmeans 和 CEEMD-PE-LSTM 的短期光伏发电功率预测[J]. *水电能源科学*,2021,39(4):204-208.
- LI Bingchen,YU Huijun,LIU Jingyu. Prediction of short-term photovoltaic power generation based on Kmeans and CEEMD-PE-LSTM[J]. *Water Resources and Power*,2021,39(4):204-208.
- [24] 王振浩,王 翀,成 龙,等. 基于集合经验模态分解和深度学习的光伏功率组合预测[J]. *高电压技术*,2022,48(10):4133-4142.
- WANG Zhenhao,WANG Chong,CHENG Long,et al. Photovoltaic power combined prediction based on ensemble empirical mode decomposition and deep learning[J]. *High Voltage Engineering*, 2022,48(10):4133-4142.
- [25] 杨仁志. 基于聚类集成分析和融合深度学习算法的光伏功率超短期预测[D]. 西安:西安理工大学,2023.
- YANG Renzhi. Ultrashort-term prediction of photovoltaic power based on clustering ensemble analysis and fusion deep learning algorithm[D]. Xi'an:Xi'an University of Technology,2023.
- [26] 陈九妹. 基于 CEEMDAN-ARO-LSTM 模型的短期光伏发电功率预测研究[D]. 南昌:江西财经大学,2023.
- CHEN Jiumei. Short term photovoltaic power prediction model based on CEEMDAN-ARO-LSTM model[D]. Nanchang:Jiangxi University of Finance and Economics,2023.

(王治红 编辑)