



基于组合深度学习的光伏功率日前概率预测模型

高岩¹, 吴汉斌¹, 张纪欣¹, 张华铭², 张沛³

(1. 国网河北省电力有限公司保定供电分公司, 河北 保定 071000; 2. 北京清软创新科技股份有限公司, 北京 102208; 3. 北京交通大学 电气工程学院, 北京 100089)

摘要: 为准确量化复杂场景下光伏预测功率的不确定性, 提出了一种基于时序卷积网络-注意力机制-长短期记忆网络组合的光伏功率短期概率预测方法。首先, 基于多种相关性分析方法选出与光伏功率强相关的气象因素; 然后, 基于时序卷积网络的特征提取能力和长短期记忆网络的时序特征建模能力, 并结合注意力机制和分位数回归, 建立组合深度学习预测模型; 最后, 采用核密度估计方法生成连续概率密度函数。以实际集中式和分布式光伏电站为案例进行分析, 结果表明: 与长短期记忆网络、时序卷积网络、时序卷积网络-注意力机制和时序卷积网络-长短期记忆网络相比, 所提方法在确保最优预测区间的同时, 可以提升概率密度预测的性能。

关键词: 概率预测; 时序卷积网络; 长短期记忆网络; 注意力机制

DOI: 10.11930/j.issn.1004-9649.202306080

0 引言

国家能源局发布 2022 年全年光伏装机情况, 全国光伏新增装机 8740.8 万 kW, 同比增长 60.3%, 分布式光伏装机 5111.4 万 kW, 约占新增装机的 58.5%^[1]。受光照强度、温度、湿度等复杂环境因素的影响, 光伏发电具有较强的随机波动性和非平稳性^[2], 给电力系统安全稳定运行带来巨大挑战。准确可靠的光伏功率预测可以提高光伏利用和保证供电可靠性。按照预测时间尺度, 光伏功率预测可以分为短期、中期和长期预测^[3]。其中, 短期预测的预测时间长度为几秒到数天, 主要应用于电网调度、提高供电质量、现货市场等。与日内短期预测所关注的即时气象条件及其实时变化不同, 日前预测更侧重其长期变化趋势和天气模式, 主要提供次日的预测结果, 为优化决策和日前电力优化调度提供重要依据^[4]。

传统的光伏功率预测研究往往以确定性预测为主, 而受光伏发电的波动性、随机性的影响,

难以对光伏预测功率的波动范围进行定量分析与估计^[5]。相较于确定性预测, 光伏功率概率预测可通过区间、分位数或概率分布形式提供电网决策所需的光伏出力不确定性量化信息, 对提高电力系统应急分析的性能、降低运营成本具有十分重要的意义。

光伏概率预测方法可分为参数估计方法和非参数估计方法^[6]。参数估计法假定光伏功率预测确定值或预测误差遵循某一特定形式的分布, 而光伏出力的实际概率分布在不同情况下的形状差异很大, 难以利用形状固定的先验分布实现准确建模^[7]。非参数估计法根据样本数据本身的特征进行分布拟合, 对于不规则的分布通用性强, 估计比较准确。常用的非参数化方法包括分位数回归 (quantile regression, QR)、核密度估计、高斯过程回归等。人工智能方法具有较强的非线性数据拟合能力, 能够挖掘多源光伏数据间复杂的非线性映射关系, 是目前光伏功率预测的常用方法。人工智能方法主要代表有支持向量回归、随机森林、卷积神经网络 (convolutional neural networks, CNN) 和循环神经网络 (recurrent neural network, RNN) 等。现有研究表明, 基于非参数估计方法与人工智能方法的概率预测方法可以对光伏出力的不确定性进行有效量化^[8-9]。文献^[10]

收稿日期: 2023-06-23; **修回日期:** 2024-02-28。

基金项目: 国网河北省电力公司科技项目 (含高比例分布式光伏的多级电网负荷预测方法研究及应用, kJ2022-051)。



提出了基于最小二乘支持向量机和鲸鱼优化算法的日前光伏功率预测方法，并根据预测误差基于核密度估计开展了日前概率预测。文献[8]考虑到QR产生可微分的损失函数，严重阻碍了改进分位数回归的CNN的训练，提出一种两阶段训练策略。首先使用确定性预测方法训练CNN，其次利用线性规划方法训练QR。但该方法仅和浅层神经网络进行对比分析，未能考虑光伏序列的时间依赖关系。

相较于CNN，以RNN为变体的长短期记忆网络（long short-term memory, LSTM），通过引入门控机制可对长时间序列中的时序特征进行提取。文献[11]通过构建多个独立的具有不同隐含单元的LSTM模型，并基于分位数回归整合多个模型的预测结果，实现了日前光伏功率概率预测。文献[9]基于多层LSTM挖掘光伏功率数据的时序特征，通过引入非交叉变化层，避免分位数交叉。该类RNN架构模型的局限性在于需要人为构建特征关系，否则难以充分提取数据中非连续特征间的有效信息^[12]。为此，文献[13]提出一种专为顺序建模而设计的时间卷积神经网络（temporal convolutional network, TCN），该网络结构结合了CNN和RNN的优点，能够提取长序列的特征信息，适合处理时间序列问题。文献[14]提出了一种基于TCN的短期光伏功率区间预测模型，采用核密度估计进行误差分析，获得模型预测输出的区间。文献[15]使用分位数回归理论与TCN结合构造分位数回归时间卷积网络（quantile regression of temporal convolution network, QRTCN）进行短期负荷预测，验证了QRTCN预测效果优于普通模型。为进一步提高光伏出力预测精度，文献[16]提出了基于TCN和注意力机制的日前光伏预测模型，利用注意力机制突出关键气象特征对光伏出力的影响，算例结果表明较所提模型TCN具有更高的预测精度。然而，该模型仅由注意力机制所得的特征量经全连接层后得到日前光伏出力，忽视了历史特征间的时序关系。

面临更加复杂多变的光伏功率波动，传统的单一模型仅能解决特定场景下的预测问题。为此，多模型融合方法被提出，其可以整合多个模型的优势，逐渐成为一种有效的解决方案^[6]。文献[17]结合分位数回归，提出了基于深度残差网

络和稠密连接网络的光伏功率日前概率预测模型，通过多重损失函数对网络进行训练增强了卷积特征提取的鲁棒性。文献[18]提出了基于CNN-LSTM的光伏出力预测方法，通过结合多种气象因素预测光伏出力，测试结果表明组合模型相比单一模型在区间预测和概率预测方面性能更佳。但是对于长期时序数据，CNN的卷积核长度容易过大，导致无法捕捉长期时间上的信息。

基于以上分析，本文考虑到单一模型难以实现复杂场景下光伏发电的准确预测，提出了一种基于时间卷积网络-注意力机制-长短期记忆网络（TCN-Attention-LSTM）的光伏短期功率概率预测方法。利用TCN的时序特征提取能力，以及注意力机制可突出重要特征的能力，挖掘光伏出力和气象因素间的深层时序特征，为减小功率急剧波动时段预测的不确定性提供重要特征支撑；基于LSTM建立高维特征与输出间的长时间序列中长期依赖关系，以处理复杂多变的天气变化引起的功率波动问题；基于分位数回归和核密度估计方法实现光伏发电功率日前概率预测。

1 光伏发电功率影响因素分析

光伏发电功率受到多种气象因素的影响，主要包括辐照度、温度、湿度、风速、风向、总云量、低云量等；同时根据测量方式的不同，辐照度还包括总辐射、直射辐照度、散射辐照度等。从数学层面和统计学方面分析多种气象因素与光伏发电功率的相关性，对光伏发电功率预测有很重要的意义，对此基于Pearson^[19]和Spearman^[20]相关系数以及最大信息系数^[21]计算各气象因素与发电功率的相关系数，并筛选出主要的影响因素。

使用华北某地区光伏电站运行数据进行相关性分析，其中气象因素有风速、环境温度、总辐射、低云量、总云量、降雨量、风向、直射辐照度以及散射辐照度。为了更加直观地显示分析结果，绘制了各相关系数的热力图，如图1所示。

由图1 a) Pearson相关系数和图1 b) Spearman相关系数可知，光伏发电功率与总辐射、直射辐照度以及散射辐照度、温度和风速正相关，与风向、降雨量、总云量、低云量负相关，其中与辐照度的相关性最大，与直射辐照度以及散射辐照




图 1 各变量相关关系分析结果

Fig. 1 Results of correlation analysis of variables

度的相关性次之，与环境温度的相关性较弱，与风速的相关性最小。同时，由图 1 c) 可知，光伏发电功率与总辐射、散射辐照度和温度的最大信息系数最大。考虑到风速与光伏发电功率的相关性较小，对光伏出力的贡献可忽略不计，因此，选取总辐射、直射辐照度、散射辐照度、温度作为光伏发电功率的主要影响因素。

2 TCN-Attention-LSTM 概率预测模型

考虑到传统的单一模型无法捕捉非晴天天气情况下急剧变化的特征，为提升光伏功率概率预测性能，本文提出基于时序卷积网络-注意力机制-长短期记忆网络的光伏电站日前功率概率预测模型，基本框架如图 2 所示。该组合深度学习模型主要由基于注意力机制的 TCN 和 LSTM 神经网络构成。基于注意力机制的 TCN 模型，不仅可以利用 TCN 挖掘光伏出力和气象因素间的深层时序特征，同时也可通过基于注意力机制可突出重要特征的能力，为减小功率急剧波动时段预测的不确定性创造有利条件；LSTM 神经网络通过建立特征间的时序依赖关系以处理复杂多变的天气变化引起的功率波动问题。




图 2 TCN-Attention-LSTM 预测流程

Fig. 2 Probabilistic prediction process of TCN-Attention-LSTM

首先将光伏功率历史数据和重要历史气象特征数据通过滑动窗口的形式，构建输入数据，输入到基于注意力机制的 TCN 模型，通过注意力机制分配特征权重，挖掘光伏发电影响因素对功率预测的深层重要时序特征向量；其次将输出向量转化为时间序列输入到 LSTM 网络中，以进一步捕捉时间序列中的长期依赖关系；然后基于 QR 用于生成预测区间；最后采用核密度估计方法生成概率预测结果。

2.1 基于注意力机制的时序卷积网络

TCN 是一种单向的卷积结构，可有效避免

RNN 面临的梯度消失和梯度爆炸问题^[22]。TCN 中的扩张因果卷积可有效防止未来信息泄露，同时也可通过调整卷积核大小、卷积层数、扩张系数等参数扩大感受野，捕捉预测时刻与更长历史时刻的依赖性，其扩张因果卷积结构如图 3 所示。




图 3 TCN 的扩张因果卷积结构

Fig. 3 Dilated causal convolution structure of TCN

给定输入序列 x ，扩张卷积位置 t 处的输出可表示为

$$F(t) = x(t) * f(t) = \sum_{i=0}^{k-1} f(i)x_{t-ai} \quad (1)$$

式中： x 是二维向量，包括历史功率和重要气象特征； f 为卷积核； k 为卷积核大小； $*$ 为卷积操作； i 表示卷积核元素的位置； a 为扩张系数，与网络层数成指数关系。同时，为了避免传统神经网络存在的梯度消失和梯度爆炸问题，并提高网络的反馈与收敛，TCN 增加了残差连接结构，通过将不同层次网络的输出和输入数据相加，并经激活函数后得到残差模块的输出。

在光伏功率预测中，某些时刻的天气状况、光照等特征会影响功率预测的精确性。同时，TCN 网络由于只能获取感受野窗内的局部时序特征信息，无法联系上下文信息突出关键特征的影响。对此，本文引入自注意力层，通过注意力机制自动学习关键特征，同时削弱其他输入特征变量对模型预测结果的干扰，使预测模型能够适用不同天气、季节条件下的光伏功率预测任务。自注意力机制的结构如图 4 所示。

给定输入矩阵 X ，经过不同的矩阵变换得到矩阵 Q 、 K 、 V 。首先，通过查询矩阵 Q 与键矩阵 K 的转置相乘计算得到其相关性矩阵；然后，通




图 4 自注意力机制

Fig. 4 Attention mechanism

过 Softmax 操作将相关性矩阵归一化；最后，将归一化的相关性矩阵乘以矩阵 V 得到自注意力层的结果，具体计算式为

$$f_{\text{Att}}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{D_k}}\right)V \quad (2)$$

式中： $Q \in R^{N \times D_k}$ 、 $K \in R^{N \times D_k}$ 、 $V \in R^{N \times D_k}$ ； N 为序列长度； D_k 为序列维度，除以 $\sqrt{D_k}$ 可以防止内积结果过大。

基于注意力机制的 TCN 模型构成的残差单元如图 5 所示。输入数据首先经过扩张因果卷积；然后对权值进行归一化处理，解决梯度爆炸的同时提高计算速度；接着利用整流线性单元 (Relu)




图 5 注意力机制 TCN 结构

Fig. 5 Structure of TCN with attention mechanism



函数使网络非线性化，再对输出数据进行 Dropout 操作；最后经过自注意力机制得到残差单元的输出。

2.2 长短期记忆网络

LSTM 网络是一种改进的递归神经网络，有效缓解了训练时梯度消失的问题^[23]。LSTM 单元由输入门、输出门和遗忘门组成，如图 6 所示。




图 6 LSTM 结构
Fig. 6 Structure of LSTM

LSTM 网络通过加入可存储信息的细胞状态功能，以学习时序数据中长时间尺度和短时间尺度的信息。以 TCN-Attention 模型输出的历史时序特征序列和待测日数值天气预报数据作为 LSTM 的输入，遗忘门可控制记忆状态 C_t 所要保留的历史时序特征信息；输入门可决定时序特征序列中哪些信息应该被记忆，据此决定对预测当前时刻的功率有用的历史时序特征信息；输出门则用于控制当前时刻的隐藏状态 h_t 向外输出的程度。LSTM 计算过程可参见文献^[24]。

2.3 分位数回归

分位数回归通过分位数逼近随机变量的条件分布^[25]，目的是为了构建随机变量的分位数 $\tilde{P}(\alpha|x)$ 与一系列相关因素 x 之间的关系，QR 模型可以表示为

$$\tilde{P}(\alpha|x) = \beta(\alpha)x \quad (3)$$

式中： $\tilde{P}(\alpha|x)$ 为在分位水平 α 下得到的预测功率点对应的第 α 个条件分位数， α 的范围为 $(0, 1)$ ； x 为输入变量； $\beta(\alpha)$ 为回归系数。

求解不同分位数点的回归系数 $\beta(\alpha)$ 的问题可以转化为最小化损失函数 L 为

$$L = \sum_{i=1}^n \gamma_{\alpha}(\tilde{P}(\alpha|x_i) - P_i) \quad (4)$$

$$\gamma_{\alpha}(s) = \begin{cases} \alpha s, & s \geq 0 \\ (\alpha - 1)s, & s < 0 \end{cases} \quad (5)$$

式中： P_i 为实际功率值； n 为功率点的个数； γ_{α} 表示不对称函数。

将不对称函数展开可以得到损失函数为

$$L_{\tau}(P_i, \tilde{P}(\alpha|x_i)) = \sum_{i=1}^n (\alpha(\tilde{P}(\alpha|x_i) - P_i) + (\alpha - 1)(\tilde{P}(\alpha|x_i) - P_i)) \quad (6)$$

在一定的置信区间 $1 - \tau$ 下，分别通过取分位数水平 α 为 $\tau/2$ 和 $1 - \tau/2$ 可以得到置信区间的上、下界。

2.4 核密度估计

核密度估计是一种用于估计概率密度函数的非参数方法，通过数据本身估计未知的密度函数^[26]。根据分位数预测结果，基于核密度估计将其转为连续的概率密度曲线。核密度估计的结果为

$$\tilde{f}_i(P) = \frac{1}{Qw} \sum_{q=1}^Q K\left(\frac{P - \tilde{P}_q(q|x_i)}{w}\right) \quad (7)$$

式中： x_i 为第 i 个样本的输入变量； P 为功率变量； Q 为第 i 个样本预测分位数数量； w 为带宽； $K()$ 为核函数； $\tilde{P}_q(q|x_i)$ 为在分位水平为 q 下得到的预测功率。核密度主要性能好坏取决于带宽 w ，确定好带宽 w 后，不同核函数的计算效果是一致的。

2.5 评价指标

2.5.1 区间评价指标

本文采用区间覆盖率 (prediction interval coverage probability, PICP)、区间平均宽度 (prediction interval normalized average, PINAW) P_{INAW} 和综合评价指标 Winkler 分数^[18] 作为区间评价指标。

P_{ICP} 定义为在一定的置信水平下实际功率值落在预测功率估计区间上下限内的概率，主要反映预测区间的可靠性。 P_{ICP} 越大，表明模型的区间预测效果越好，计算式为

$$P_{ICP} = \frac{1}{N} \sum_{i=1}^N Z(P_i) \times 100\% \quad (8)$$

$$Z(P_i) = \begin{cases} 1, & P_i \in [L_i^{\tau}, U_i^{\tau}] \\ 0, & P_i \notin [L_i^{\tau}, U_i^{\tau}] \end{cases} \quad (9)$$

式中： $Z(P_i)$ 为布尔量； L_i^{τ} 、 U_i^{τ} 分别为 $1 - \tau$ 置信水

平下概率预测区间的上、下限； N 为样本数量。

P_{INAW} 定义为所有预测区间宽度的平均值，主要反映预测分布的离散程度，衡量区间的锐度。在 P_{ICP} 一定时， P_{INAW} 越小，表明模型的区间预测效果越好，计算式为

$$P_{\text{INAW}} = \frac{1}{NC} \sum_{i=1}^N (U_i^T - L_i^T) \quad (10)$$

式中： C 为实际功率的最大值和最小值之差。

Winkler 分数 S_W 通过对区间的可靠性和锐度进行加权，实现对总体性能的评价，该分数越小越好，计算式为

$$S_W = (U_i^T - L_i^T) + \frac{2}{\tau} (L_i^T - P_i) v(x) (L_i^T - P_i) + \frac{2}{\tau} (P_i - U_i^T) v(x) (P_i - U_i^T) \quad (11)$$

$$v(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (12)$$

式(11)右侧第1项是对预测区间锐度的评估，预测区间越宽，则第1项会贡献越大的正值；后2项是对预测区间可靠性的评估，当预测区间未能覆盖实际值的时候，后2项会贡献较大的正值，且实际值距离区间边界越远，此正值越大，当预测区间成功覆盖实际值时，后2项变为零。

2.5.2 概率密度评价指标

本文采用连续等级概率分数 (continuous ranked probability score, CRPS) P_{CRPS} 作为概率密度预测评价指标，该值越小则表明概率预测效果越好，计算式为

$$P_{\text{CRPS}} = \int_{-\infty}^{+\infty} (\hat{F}_t(x) - F_t(x))^2 dx \quad (13)$$

式中： $F_t(x)$ 为真实概率分布； $\hat{F}_t(x)$ 为预测概率分布。

但是，实际光伏功率值的真实概率分布 $F_t(x)$ 难以获取，通常利用实际功率值的经验概率分布替代真实概率分布。单一实际功率值 P_i 对应的经验概率分布为

$$F_t(x) = v(x - P_i) \quad (14)$$

假设共有 N 个样本，则这些样本的平均 CRPS 为

$$P_{\text{CRPS}} = \frac{1}{N} \sum_{i=1}^N \left[\int_{-\infty}^{P_i} \hat{F}^2(x) dx + \int_{P_i}^{+\infty} (\hat{F}(x) - 1)^2 dx \right] \quad (15)$$

3 算例结果与分析

3.1 数据说明

本文以华北某地区集中式和分布式光伏电站采集的实际功率和数值天气预报数据为例进行案例分析，集中式光伏电站装机容量为 17.5 MW，数据采样区间 2018 年 7 月 1 日—2019 年 6 月 13 日，以 15 min 为采样频率，去除夜晚的数据，共有 16 551 个数据。分布式户用光伏装机容量为 38 kW，数据采样区间 2021 年 9 月 10 日—2021 年 11 月 21 日，以 15 min 为采样频率，去除夜晚的数据，共有 3 796 个数据。

3.2 数据预处理

滑动窗口法用于将长期时间序列分割以获得固定的输入窗口和输出窗口。针对未来 24 h 光伏功率概率预测，输入窗口可以表示为 $X = \{x_1, x_2, \dots, x_m\}$ ，输出窗口可以表示为 $Y = \{x_{m+1}, x_{m+2}, \dots, x_{m+n}\}$ ，即预测步长为 n 。其中， x_1 是 4 维向量，包括直射辐照度、散射辐照度、温度和功率数据； x_{m+1} 作为标签是一维向量，表示功率数据，滑动窗口划分如图 7 所示。




图 7 滑动窗口划分

Fig. 7 Sliding window partitioning

3.3 模型参数选取

分别以待测日的前一日实测及待测日数值天气预报中的直射辐照度、散射辐照度、温度和功率数据作为预测模型的输入 X ，模型的输出为设置分位点处待测日的光伏功率预测值。分位数的取值范围为区间 $[0.05, 0.95]$ ，间隔为 0.05，共 19 个。基于 TCN-Attention-LSTM 模型的光伏功率日前概率预测工作流程如图 8 所示。

通过对案例进行多次反复验证分析，确定最优的 Attention-TCN-LSTM 预测模型的网络结构和




图 8 光伏功率日前概率预测工作流程
Fig. 8 Workflow of day-ahead probabilistic prediction of PV power

模型参数如表 1 所示。表 1 中， i 为 TCN 输入通道； o 为 TCN 输出通道； p 为零填充系数； d 为扩张系数； k 为卷积核大小； i_L 为 LSTM 输入维度； n_1 为隐藏层的数目； h_s 为隐藏层维数； i_N 为全连接层输入维度； o_N 为全连接层输出维度。同时，表 1 中所显示的网络结构前后顺序与实际模型搭

表 1 TCN-Attention-LSTM 主要结构超参数设置
Table 1 Hyperparameters setting for main structure of TCN- Attention-LSTM

结构名称	超参数设置
TCN#1	$i=2, o=10, p=3, d=1, k=4$
TCN#2	$i=10, o=10, p=9, d=3, k=4$
TCN#3	$i=10, o=10, p=18, d=6, k=4$
LSTM	$i_L=10, n_1=2, h_s=128$
全连接层	$i_N=128, o_N=58$

建的顺序一致。

为了验证本文所提出的 TCN-Attention-LSTM 模型预测效果，分别建立以下 5 个模型进行对比分析。模型 1：基于 LSTM 基本原理所构建的 QRLSTM 模型；模型 2：基于 1.1 节 TCN 基本原理所构建的 QRTCEN 模型；模型 3：基于 1.1 节 TCN-Attention 基本原理所构建的 QRTCEN-Attention 模型；模型 4：利用 TCN 提取输入数据的高维特征，并用 LSTM 学习高维特征间的长期时间依赖关系；模型 5：即本文所提出的模型，在模型 4 的基础上，在 TCN 层引入注意力机制。各种模型共同超参数设置如表 2 所示。

表 2 模型共同超参数
Table 2 Common hyperparameters of model

参数	数值
学习率	0.001
批处理参数	32
优化器	Adam
训练集：测试集	9：1

3.4 区间预测结果分析

以集中式和分布式光伏为案例进行模型对比分析，各模型的光伏功率区间预测评价指标以及模型训练所需要的时间如表 3 所示。

以集中式光伏电站测试结果为例，由表 3 可知，本文提出的 TCN-Attention-LSTM 神经网络模型的区间覆盖率相较模型 1 提高了 3.39 个百分点，

表 3 90% 置信区间各模型评价指标以及模型训练所需要的时间
Table 3 Evaluation metrics of each model within a 90% confidence interval and training time of different models

数据	模型	$P_{ICP}/\%$	P_{INAW}/kW	S_W 分数/ kW	训练时 间/s
集中式	LSTM	93.79	0.2979	5.5948	1603.97
	TCN	96.57	0.3473	5.7086	121.89
	TCN-Attention	98.28	0.3693	5.9472	201.41
	TCN-LSTM	95.14	0.3259	5.7438	4260.87
	TCN-Attention-LSTM	97.18	0.3099	5.1763	5008.32
分布式	LSTM	88.68	0.3229	7.6214	912.94
	TCN	96.60	0.4497	10.2056	33.72
	TCN-Attention	92.08	0.3211	7.9540	122.67
	TCN-LSTM	94.34	0.3525	8.9185	1039.98
	TCN-Attention-LSTM	93.96	0.2674	7.2308	1168.41



较模型 2 提高了 0.61 个百分点，较模型 4 提高了 2.04 个百分点。虽然相比模型 3 模型区间覆盖率有所降低，但彼此间相差较小，较模型 3 降低了 1.1 个百分点。从表 3 可知，在区间覆盖率得到提升的同时，可能会使得区间平均宽度下降。模型 1 的区间平均宽度明显低于其他模型，模型 5 较模型 1 提高了 4.03%，较模型 2 降低了 10.76%，较模型 3 降低了 16.08%，较模型 4 降低了 4.91%。由于区间覆盖率和区间平均宽度在评价区间预测结果时可能会发生冲突，本文使用 Winklers 分数作为综合区间预测评价指标，进而反映模型 5 的优势。模型 5 Winklers 分数较模型 1 降低了 7.48%，较模型 2 降低了 9.32%，较模型 3 降低了 12.96%，较模型 4 降低了 9.88%。此外，由表 3 可知，与单一预测模型 LSTM、TCN 相比，组合预测模型的训练时间开销相对较大，表明随着模型复杂度增加，模型的训练时间也会相应提高。

为了更直观对比分析 5 种模型在光伏功率概率预测中的性能，以集中式光伏电站为例，图 9 和图 10 分别展示了 5 种模型在晴天和阴雨天 90% 置信区间下的预测结果。




图 9 晴天时 90% 置信区间各模型预测对比
Fig. 9 Comparison of model predictions within a 90% confidence interval in sunny days

由图 9 可知，在光伏出力呈现平稳上爬坡状态或下爬坡的过程中，5 种模型均能较好地量化不确定性，但本文所提出的模型 5 的预测区间相比于其他模型更窄。相对于模型 1 和模型 2，模型 4 和模型 5 在上坡或下坡状态的预测区间更窄，这反映了混合模型在光伏出力预测的优势。此外，在峰谷时刻，本文所提出的模型也获得最窄的预测区间。

由图 10 可知，在一天功率波动较大的情况




图 10 阴雨天时 90% 置信区间各模型预测对比
Fig. 10 Comparison of model predictions within a 90% confidence interval in rainy days

下，预测结果中波动平缓的时段区间较窄，急剧波动的时段区间较宽，能够追踪光伏出力的波动特性并量化其不确定性，符合预期要求。

3.5 概率密度预测结果分析

以集中式和分布式光伏为案例进行模型对比分析，表 4 给出了本文所提出的 TCN-Attention-LSTM 和 4 种对比模型概率密度的评价结果。

表 4 各种模型 CRPS 评价指标
Table 4 CRPS evaluation metrics for various models

数据	模型	C_{RPS}/kW
集中式	LSTM	0.058 9
	TCN	0.053 9
	TCN-Attention	0.050 7
	TCN-LSTM	0.043 3
	TCN-Attention-LSTM	0.042 1
分布式	LSTM	0.047 8
	TCN	0.056 5
	TCN-Attention	0.050 5
	TCN-LSTM	0.044 5
	TCN-Attention-LSTM	0.044 1

以集中式光伏电站测试结果为例，由表 4 可知，本文所提出的 TCN-Attention-LSTM 模型得到的 CRPS 结果明显低于其他模型，较模型 1 降低了 28.52%，较模型 2 降低了 21.89%，较模型 3 降低了 16.96%，较模型 4 降低了 2.77%。由分析结果可知，组合模型的 CRPS 结果远低于单一模型，表明组合模型能够整合单一模型的优势。此外，在单一模型和组合模型引入注意力机制后，均能在一定程度上提升模型预测性能，但从表 4 中可



以看出,注意力机制对预测效果的提升低于组合模型的方法。

进一步,以集中式光伏电站为例,图 11 分别

绘制了 5 月 21 日功率平稳变化和 5 月 24 日功率波动变化 2 天中,TCN-Attention-LSTM 模型在 07:30、12:00 和 14:30 3 个时间点的概率密度预测结果。




图 11 TCN-Attention-LSTM 概率密度预测结果

Fig. 11 Probability density prediction results of TCN- Attention-LSTM

从图 11 可以看出,光伏功率实际值多数位于概率密度曲线的最大值附近,这表明概率密度预测结果可靠。在功率波动较大的日期下,实际值远离曲线的最大值,表明此时预测误差较高,可以结合区间预测的结果为电力系统调度提供决策依据。

4 结论

本文提出了基于 TCN-Attention-LSTM 组合模型的光伏发电短期功率概率预测模型。基于 TCN 模型学习输入信息的高维特征,利用注意力机制进行信息权重自适应选择并构建 LSTM 模型,建立高维特征与输出间的非线性映射关系得到光伏功率的预测区间和概率密度。以实际集中式和分布式光伏电站为案例进行分析,可得到以下结论。

1) 结合注意力机制的 TCN 模型能够挖掘输入信息的高维概率特征,包括天气变化造成的短

期光伏出力波动和长期稳定状态。在晴天和阴雨天气下,均符合概率预测的可靠性要求。

2) TCN- Attention-LSTM 模型与 LSTM、TCN、TCN -Attention 和 TCN-LSTM 模型对比,在确保预测区间最优的同时,概率密度预测指标 CRPS 最低,可以提升光伏功率短期概率预测质量。

3) TCN-Attention-LSTM 模型的泛化能力强,不仅适用于集中式光伏概率预测,而且适用于小样本的分布式光伏功率日前概率预测。

参考文献:

- [1] 国家能源局. 2022 年光伏发电建设运行情况 [EB/OL]. (2023-02-17)[2023-05-25]. http://www.nea.gov.cn/2023-02/17/c_1310698128.htm.
- [2] 卢俊杰,蔡涛,郎建勋,等. 基于集群划分的光伏电站集群发电功率短期预测方法 [J]. 高电压技术, 2022, 48(5): 1943–1951.
LU Junjie, CAI Tao, LANG Jianxun, *et al.* Short-term power output



- forecasting of clustered photovoltaic solar plants based on cluster partition[J]. *High Voltage Engineering*, 2022, 48(5): 1943–1951.
- [3] SANGRODY H, ZHOU N, ZHANG Z A. Similarity-based models for day-ahead solar PV generation forecasting[J]. *IEEE Access*, 2020, 8: 104469–104478.
- [4] 杨茂, 闫琦, 苏欣, 等. 季节分型下一种面向风电功率日前预测的深度自适应滤波框架[J]. *南方电网技术*, 2023, 17(6): 62–71.
- YANG Mao, YAN Qi, SU Xin, *et al.* A depth self-adaptive filtering framework for wind power day-ahead prediction under seasonal classification[J]. *Southern Power System Technology*, 2023, 17(6): 62–71.
- [5] LINDBERG O, LINGFORS D, ARNQVIST J, *et al.* Day-ahead probabilistic forecasting at a co-located wind and solar power park in Sweden: trading and forecast verification[J]. *Advances in Applied Energy*, 2023, 9: 100120.
- [6] 万灿, 崔文康, 宋永华. 新能源电力系统概率预测: 基本概念与数学原理[J]. *中国电机工程学报*, 2021, 41(19): 6493–6509.
- WAN Can, CUI Wengkang, SONG Yonghua. Probabilistic forecasting for power systems with renewable energy sources: basic concepts and mathematical principles[J]. *Proceedings of the CSEE*, 2021, 41(19): 6493–6509.
- [7] GOLESTANEH F, PINSON P, GOOI H B. Very short-term nonparametric probabilistic forecasting of renewable energy generation—with application to solar energy[J]. *IEEE Transactions on Power Systems*, 2016, 31(5): 3850–3863.
- [8] HUANG Q, WEI S Y. Improved quantile convolutional neural network with two-stage training for daily-ahead probabilistic forecasting of photovoltaic power[J]. *Energy Conversion and Management*, 2020, 220: 113085.
- [9] 项明俊. 基于地基云图的光伏发电功率概率预测[D]. 杭州: 浙江大学, 2022.
- XIANG Mingjun. Probabilistic forecasting of photovoltaic power generation based on ground cloud images[D]. Hangzhou: Zhejiang University, 2022.
- [10] GU B, SHEN H Q, LEI X H, *et al.* Forecasting and uncertainty analysis of day-ahead photovoltaic power using a novel forecasting method[J]. *Applied Energy*, 2021, 299: 117291.
- [11] MEI F, GU J Q, LU J X, *et al.* Day-ahead nonparametric probabilistic forecasting of photovoltaic power generation based on the LSTM-QRA ensemble model[J]. *IEEE Access*, 2020, 8: 166138–166149.
- [12] 姚程文, 杨苹, 刘泽健. 基于 CNN-GRU 混合神经网络的负荷预测方法[J]. *电网技术*, 2020, 44(9): 3416–3424.
- YAO Chengwen, YANG Ping, LIU Zejian. Load forecasting method based on CNN-GRU hybrid neural network[J]. *Power System Technology*, 2020, 44(9): 3416–3424.
- [13] BAI S J, ZICO KOLTER J, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. *ArXiv e-Prints*, 2018: arXiv: 1803.01271.
- [14] 宋绍剑, 姜屹远, 刘斌. 一种 TCN 的改进模型及其在短期光伏功率区间预测的应用[J]. *计算机应用研究*, 2023, 40(10): 3064–3069.
- SONG Shaojian, JIANG Yiyuan, LIU Bin. Improved TCN model and its application in short-term photovoltaic power interval prediction[J]. *Application Research of Computers*, 2023, 40(10): 3064–3069.
- [15] 庞昊, 高金峰, 杜耀恒. 基于时间卷积网络分位数回归的短期负荷概率密度预测方法[J]. *电网技术*, 2020, 44(4): 1343–1350.
- PANG Hao, GAO Jinfeng, DU Yaoheng. A short-term load probability density prediction based on quantile regression of time convolution network[J]. *Power System Technology*, 2020, 44(4): 1343–1350.
- [16] 陈禹帆, 温蜜, 张凯, 等. 基于相似日匹配及 TCN-Attention 的短期光伏出力预测[J]. *电测与仪表*, 2022, 59(10): 108–116.
- CHEN Yufan, WEN Mi, ZHANG Kai, *et al.* Short-term photovoltaic output forecasting based on similar day matching and TCN-Attention[J]. *Electrical Measurement & Instrumentation*, 2022, 59(10): 108–116.
- [17] ZANG H X, CHENG L L, DING T, *et al.* Day-ahead photovoltaic power forecasting approach based on deep convolutional neural networks and meta learning[J]. *International Journal of Electrical Power & Energy Systems*, 2020, 118: 105790.
- [18] 王开艳, 杜浩东, 贾嵘, 等. 基于相似日聚类 and QR-CNN-BiLSTM 模型的光伏功率短期区间概率预测[J]. *高电压技术*, 2022, 48(11): 4372–4388.
- WANG Kaiyan, DU Haodong, JIA Rong, *et al.* Short-term interval probabilistic forecasting of photovoltaic power based on similar day clustering and QR-CNN-BiLSTM model[J]. *High Voltage Engineering*, 2022, 48(11): 4372–4388.
- [19] 刘昶娟, 陈云龙, 刘继彦, 等. 基于集成学习的分布式光伏发电功率日前预测[J]. *中国电力*, 2022, 55(9): 38–45.
- LIU Yijuan, CHEN Yunlong, LIU Jiyan, *et al.* Ensemble learning-based day-ahead power forecasting of distributed photovoltaic generation[J]. *Electric Power*, 2022, 55(9): 38–45.
- [20] 黄书民, 蒋林高, 李志川, 等. 基于 PSO 寻优与 DBN 神经网络的电晕损耗预测[J]. *中国电力*, 2022, 55(6): 95–102, 214.
- HUANG Shumin, JIANG Lingao, LI Zhichuan, *et al.* Corona loss prediction of UHV AC transmission line based on DBN neural network optimized by PSO[J]. *Electric Power*, 2022, 55(6): 95–102,



214.

- [21] 冯裕祺, 李辉, 李利娟, 等. 基于 CNN-GRU 的光伏电站电压轨迹预测 [J]. 中国电力, 2022, 55(7): 163–171.

FENG Yuqi, LI Hui, LI Lijuan, *et al.* Voltage trajectory prediction of photovoltaic power station based on CNN-GRU[J]. Electric Power, 2022, 55(7): 163–171.

- [22] 刘辉, 凌宁青, 罗志强, 等. 基于 TCN-LSTM 和气象相似日集的电网短期负荷预测方法 [J]. 智慧电力, 2022, 50(8): 30–37.

LIU Hui, LING Ningqing, LUO Zhiqiang, *et al.* Power grid short-term load forecasting method based on TCN-LSTM and meteorological similar day sets[J]. Smart Power, 2022, 50(8): 30–37.

- [23] 符杨, 任子旭, 魏书荣, 等. 基于改进 LSTM-TCN 模型的海上风电超短期功率预测 [J]. 中国电机工程学报, 2022, 42(12): 4292–4303.

FU Yang, REN Zixu, WEI Shurong, *et al.* Ultra-short-term power prediction of offshore wind power based on improved LSTM-TCN model[J]. Proceedings of the CSEE, 2022, 42(12): 4292–4303.

- [24] 赵雅雪, 王旭, 蒋传文, 等. 基于最大信息系数相关性分析和改进多层级门控 LSTM 的短期电价预测方法 [J]. 中国电机工程学报, 2021, 41(1): 135–146, 404.

ZHAO Yaxue, WANG Xu, JIANG Chuanwen, *et al.* A novel short-term electricity price forecasting method based on correlation analysis with the maximal information coefficient and modified multi-hierarchy gated LSTM[J]. Proceedings of the CSEE, 2021,

41(1): 135–146, 404.

- [25] HE Y Y, XU Q F, WAN J H, *et al.* Short-term power load probability density forecasting based on quantile regression neural network and triangle kernel function[J]. Energy, 2016, 114: 498–512.

- [26] DONG W C, SUN H X, TAN J X, *et al.* Regional wind power probabilistic forecasting based on an improved kernel density estimation, regular vine copulas, and ensemble learning[J]. Energy, 2022, 238: 122045.

作者简介:

高岩 (1982—), 男, 学士, 高级工程师, 从事新能源运行管理工作, E-mail: bd_gaoy@he.sgcc.com.cn;

吴汉斌 (1969—), 男, 学士, 高级工程师, 从事电网调度运行工作, E-mail: bd_wuhb@he.sgcc.com.cn;

张纪欣 (1990—), 男, 学士, 工程师, 从事新能源调度和功率预测工作, E-mail: bddkzy@126.com;

张华铭 (1967—), 男, 硕士, 高级工程师, 从事电力系统负荷预测、新能源发电功率预测、电力市场研究, E-mail: hmzhang@tsingsoft.com.cn;

张沛 (1972—), 男, 通信作者, 博士, 教授, 博士生导师, 从事新能源与电力信息化、电力系统规划技术研究, E-mail: pizhang166@qq.com.

(责任编辑 许晓艳)

Day-Ahead Probabilistic Prediction Model for Photovoltaic Power Based on Combined Deep Learning

GAO Yan¹, WU Hanbin¹, ZHANG Jixin¹, ZHANG Huaming², ZHANG Pei³

(1. Baoding Power Supply Branch, State Grid Hebei Electric Power Co., Ltd., Baoding 071000, China; 2. Beijing Qingsoft Innovation Technology Co., Ltd., Beijing 102208, China; 3. School of Electrical Engineering, Beijing Jiaotong University, Beijing 100089, China)

Abstract: To accurately quantify the uncertainty in the predicted photovoltaic (PV) power in complex scenarios, a short-term probabilistic prediction method for PV power based on a combination of temporal convolutional networks-attention mechanism-long short-term memory networks is proposed in this paper. Firstly, meteorological factors strongly correlated with PV power are selected based on multiple correlation analysis methods. Then, a combined deep learning prediction model is built based on the feature extraction capability of the temporal convolutional network and the temporal feature modeling capability of the long and short-term memory network, combined with the attention mechanism and quantile regression. Finally, a kernel density estimation method is used to generate a continuous probability density function. The cases of actual centralized and distributed PV plants are analyzed, and the results show that compared with long short-term memory networks, temporal convolutional networks, temporal convolutional networks-attention mechanism, and temporal convolutional networks-long short-term memory networks, the proposed method can improve the performance of probability density prediction while ensuring the optimal prediction interval.

This work is supported by State Grid Hebei Electric Power Co., Ltd. (Load Forecasting Methods for Multiple Level Power Grid with High Penetration of Distributed Photovoltaic Generation, No.kj2022-051).

Keywords: probabilistic prediction; temporal convolutional network; long short-term memory network; attention mechanism